


2. SDA의 원리

2.1. SDA의 본질과 특성

공간적인 것은 특별하다!



-공간데이터가 특별한 세 가지 측면

- 연구 데이터: 공간데이터
- 연구 대상: 공간적 변동
- 연구 방법론: 공간데이터분석, 공간통계학

연구 데이터: 공간데이터

-관측지(地)-관측치(値) 프레임워크: 개체-속성 프레임워크의 공간적 확장

관측지	-관측 개체가 위치하는 공간상의 특정한 지점(들) -차원성: 점/선/역/면 ① 관측지의 위치 정보 location ② 관측지간의 공간 관계 정보: point 간의 distance / 역 간의 contiguity(연접성) / 선 간의 intersection				
관측치	-관측치가 보유한 속성 spatial relationship -변수: 명목/서열/등간/비율 척도 <table border="1"> <tr> <td>이산적 변수</td><td>-공간적으로 <u>연연적</u>(spatially extensive) 변수: 카운트(count) ㉠ 인구수</td></tr> <tr> <td>연속적 변수</td><td>-공간적으로 <u>내포적</u>(spatially intensive) 변수: 표준화, 정규화 변수 ㉡ 인구 밀도</td></tr> </table>	이산적 변수	-공간적으로 <u>연연적</u> (spatially extensive) 변수: 카운트(count) ㉠ 인구수	연속적 변수	-공간적으로 <u>내포적</u> (spatially intensive) 변수: 표준화, 정규화 변수 ㉡ 인구 밀도
이산적 변수	-공간적으로 <u>연연적</u> (spatially extensive) 변수: 카운트(count) ㉠ 인구수				
연속적 변수	-공간적으로 <u>내포적</u> (spatially intensive) 변수: 표준화, 정규화 변수 ㉡ 인구 밀도				

□ '뭉쳐 있다' = (1) 값들의 relation + (2) 값을 가진 개체의 relation

-공간데이터의 유형

지형통계학적	공간적 포인트 패턴 데이터	에어리어 데이터	지구통계학적 데이터	그리드 데이터	공간적 상호작용 데이터
	관측지	모든 위치	고정된 에어리어 (불규칙 테셀레이션)	고정된 그리드 셀 (규칙 테셀레이션)	관측지의 쌍 (방향성 고려 가능)
관측치	속성이 확률변수 (이항, 다항, 비율)	속성이 확률변수 (주로 등간/비율척도)	속성이 확률변수 (주로 등간/비율척도)	속성이 확률변수 (주로 등간/비율척도)	관계적 속성이 확률변수 (주로 등간/비율척도)
예	교통사고 데이터	센서스 데이터 (행정구역별)	필드 표본 데이터	원격탐사 데이터	인구 이동 데이터

공간적 포인트 패턴 데이터	-점형 사건 → 위치 자체가 확률변수 / 속성의 역할 없음
에어리어 데이터	-역형 개체가 보유한 속성
지구통계학적 데이터	-점형 개체가 보유한 속성 (sampling point) → interpolation 하기도
그리드 데이터	-공간 일반이 보유한 속성 → 그리드 셀이 보유한 속성
공간적 상호작용 데이터	-개체 간의 관계적 속성 → 두 지점과 모두 연관, directional / interactional.

연구 대상: 공간적 변동

-공간적 데이터는 공간적 변동(spatial variation)을 설명함

remark: 회귀분석 - 종속변수의 변동 설명.

일반적 변동	-속성(값)의 다양성 -다양한 값들의 빈도(확률) 분포 -히스토그램, 박스플롯
공간적 변동	-속성(값)의 다양성 + 공간적 분포 -다양한 값들이 공간상에 배열되어 있는 양태 → 공간적 패턴(= 눈에 띄는 공간적 변동) 예) 군집 분포, 분산 분포, 무작위 분포 -시각화: 지도 (지도를 통해서만 확인 가능!) -두 확률 → interaction (?) → 이 (관계) 관련이 있는 확률? (무작위인 확률 → 작음) • 공간적 패턴의 발생 확률: 100개 sampling → Moran's i 계산 → 가설 검정 (다른 모집단에서 나온 것?) • 확률의 공간적 분포: 속성값 가질 확률 같은가? → 자기상관을 만들어내는 process 있는가?

-공간적 변동의 분해

	1차 효과	2차 효과
변동의 원인	지역적 경향성	국지적 상호작용
지리적 범위	광역	협역
모델의 속성	결정론적 (predictable)	무작위적 (random)
변동의 구조	평균의 구조	오차의 구조
관련 통계적 속성	기대값	공분산

→ 1차 효과와 2차 효과를 엄밀히 구분하기는 어려움 (연구자의 몫)


→ 원인과 결과 X.

→ 기댓값에서 벗어난 값.

연구 방법론: SDA

공간데이터의 특수성을 반영 → 공간적 변동에 대한 분석이 가능한 연구방법론: 속성 + 위치, 공간관계를 다룸

→ SDA: 공간적 데이터를 시각화(visualizing)·탐색(exploring)·모델링(modeling) 할 수 있게 해주는 분석 기법의 총체



예) edge effect: 일반 통계학에서 다룰 수 없음 - 경계 즉 data에 대한 correction..

-SDA의 공간통계학적 원리

- 공간통계학: 관찰된 공간적 변동을 공간적 확률과정(spatial stochastic processes)의 산물로 인식하고, 그 과정을 모델화함으로써 관찰된 변동에 대한 통계학적인 기술과 추론을 행하며 더 나아가 관찰되지 않은 공간적 변동에 대한 예측을 행함
- 두 가지 개념: 공간적 확률과정, 공간통계학적 가설 검정

공간적 확률과정	-공간적 변동(패턴)을 발생시키는 확률론적 메커니즘 • “모든 공간적 변동은 특정한 공간적 확률과정의 산물” 특정한 공간적 변동은 특정한 공간적 확률과정이 만들어 낼 수 있는 수많은 공간적 변동 중 하나 -공간적 확률과정의 구성 요소: $Y = E[Y] + \epsilon$ <table border="1"> <tr> <td>결정론적 요소</td><td>-외생적으로 결정 → 예측 가능 예) OLS의 회귀식에 의한 추정값(기대값) $E[Y]$</td></tr> <tr> <td>무작위적 요소</td><td>-보통 확률분포에 의거해 발생 → 예측 불가능 예) OLS의 잔차: $\epsilon \sim N(0, \sigma^2)$ → random</td></tr> </table> 예) 64개의 point에 대한 공간적 확률과정 $z = 2x + 3y + 1$ → 2^{64}가지 공간적 변동 나올 수 있음 -비공간적 확률과정: '지리는 없다' → 귀무가설의 역할 • IRP(independent random process; 독립무작위과정) • CSR(complete spatial randomness; 완전공간무작위성)	결정론적 요소	-외생적으로 결정 → 예측 가능 예) OLS의 회귀식에 의한 추정값(기대값) $E[Y]$	무작위적 요소	-보통 확률분포에 의거해 발생 → 예측 불가능 예) OLS의 잔차: $\epsilon \sim N(0, \sigma^2)$ → random
결정론적 요소	-외생적으로 결정 → 예측 가능 예) OLS의 회귀식에 의한 추정값(기대값) $E[Y]$				
무작위적 요소	-보통 확률분포에 의거해 발생 → 예측 불가능 예) OLS의 잔차: $\epsilon \sim N(0, \sigma^2)$ → random				

지리는 공간하지 않음!

(관련 값에 의해 발생하지 않음!)

↔ 재검정: 특정한 공간적 process에 의해 만들어진 것.

	-IRP/CSR의 두 가지 조건 <table border="1"> <tr> <td>동일</td><td>-(point pattern data) 모든 지점은 사건 발생의 동일한 확률을 가짐</td></tr> <tr> <td>확률</td><td>-모든 공간적 개체의 속성값은 동일한 확률분포에 의거해 주어짐 → 기댓값/분산이 동일</td></tr> <tr> <td>독립성</td><td>-(point pattern data) 한 사건의 발생 지점은 다른 사건의 발생 지점에 영향을 받지 않음 -한 공간적 개체의 속성값은 다른 공간적 개체의 속성값에 영향을 받지 않음</td></tr> </table> ☆ -무작위적 과정 vs. 무작위적 패턴 - 공간적 확률과정이 무작위적이라 하더라도, 그러한 과정에 의해 생성된 패턴이 반드시 무작위적인 것 아님 - 가설 검정: 5% 이하 발생 확률 → 유연히 발생한 것 아니라 (CSR이 아닌) 다른 프로세스 의해 발생	동일	-(point pattern data) 모든 지점은 사건 발생의 동일한 확률 을 가짐	확률	-모든 공간적 개체의 속성값은 동일한 확률분포 에 의거해 주어짐 → 기댓값/분산이 동일	독립성	-(point pattern data) 한 사건의 발생 지점은 다른 사건의 발생 지점에 영향을 받지 않음 -한 공간적 개체의 속성값은 다른 공간적 개체의 속성값에 영향을 받지 않음		
동일	-(point pattern data) 모든 지점은 사건 발생의 동일한 확률 을 가짐								
확률	-모든 공간적 개체의 속성값은 동일한 확률분포 에 의거해 주어짐 → 기댓값/분산이 동일								
독립성	-(point pattern data) 한 사건의 발생 지점은 다른 사건의 발생 지점에 영향을 받지 않음 -한 공간적 개체의 속성값은 다른 공간적 개체의 속성값에 영향을 받지 않음								
공간통계학적 가설 검정	-가설 <table border="1"> <tr> <td>귀무가설</td><td>-패턴에 유의미한 수준의 공간적 자기상관은 존재하지 않음: 공간적 무자기상관 -주어진 패턴은 비공간적 프로세스(IRP/CSR)로 만들어진 것임</td></tr> <tr> <td>대립가설</td><td>-주어진 패턴에 유의미한 수준의 공간적 자기상관이 존재함 -주어진 패턴은 공간적 자기상관을 만드는 프로세스로 만들어진 것임</td></tr> </table> -통계량 <table border="1"> <tr> <td>측정통계량</td><td>-공간적 자기상관의 측정: Moran's i, etc.</td></tr> <tr> <td>검정통계량</td><td>-표본분포: (주로) 정규분포 → Z 검정 -검정통계값</td></tr> </table> -검정통계값 유의수준에 의한 임계값보다 크면(혹은 작으면), 혹은 유의확률이 유의수준보다 작으면 통계적으로 유의미한 수준의 공간적 자기상관이 존재함 ☆ 이론적 permutation...	귀무가설	-패턴에 유의미한 수준의 공간적 자기상관 은 존재하지 않음: 공간적 무자기상관 -주어진 패턴은 비공간적 프로세스(IRP/CSR)로 만들어진 것임	대립가설	-주어진 패턴에 유의미한 수준의 공간적 자기상관 이 존재함 -주어진 패턴은 공간적 자기상관을 만드는 프로세스로 만들어진 것임	측정통계량	-공간적 자기상관의 측정: Moran's i, etc.	검정통계량	-표본분포: (주로) 정규분포 → Z 검정 -검정통계값
귀무가설	-패턴에 유의미한 수준의 공간적 자기상관 은 존재하지 않음: 공간적 무자기상관 -주어진 패턴은 비공간적 프로세스(IRP/CSR)로 만들어진 것임								
대립가설	-주어진 패턴에 유의미한 수준의 공간적 자기상관 이 존재함 -주어진 패턴은 공간적 자기상관을 만드는 프로세스로 만들어진 것임								
측정통계량	-공간적 자기상관의 측정: Moran's i, etc.								
검정통계량	-표본분포: (주로) 정규분포 → Z 검정 -검정통계값								

*Moran's i에 대한 simulation (permutation): 나올 수 있는 조합의 개수: $n! / \prod_{j=1}^k n_j!$ (pattern) → Moran's i 불변 가능했어.

-공간통계량의 종류

	전역적	국지적
목적	-공간적 등질성 ② L 전체가 어느정도 차이는?	-공간적 이질성
특징	-singly valued -invariant over space -spatial similarities -non-mappable -GIS-friendly unfriendly. -search for regularities -spatially limited ㉠ Moran's i	-multivalued -variant over space -spatial difference -mappable -GIS-friendly/GISable -search for exceptions -spatially enabled ㉠ local Moran's i

→ 전역적으로 자기상관 없더라도 국지적으로 positive/negative 자기상관 존재 가능 (상쇄됨)

-SDA의 유형

	확증적 공간데이터 분석 (CSDA)	탐색적 공간데이터 분석 (ESDA)
목적	-가설검정, modeling	-가설설정
특징	-data screening -process speculation -model variation -parameterization -inferential -global -GIS-unfriendly	-data mining -pattern detection -model evaluation -visualization -descriptive -local -GIS-friendly

-GIS와 SDA의 결합: Luc Anselin의 역할

GeoDa 개발

2.2. SDA의 근본 개념

4가지: 공간적 스케일, 공간적 이질성, 공간적 이질성, 공간적 공간패러미터

공간적 스케일(spatial scale)

-공간적 스케일의 종류 4가지

지도 스케일	-지도 축척(map scale): 현실 공간이 지도 공간에서 축소되는 정도 -지도학적 일반화(cartographic generalization): 축척지의 차원 -대축척 $\rightarrow$ 소축척: dimension의 삭감, 일어날 수 있음 예) area가 point로 $\rightarrow$ spatial configuration 달라짐
지리 스케일	-관찰 스케일(observational scale) -연구 대상 전체의 공간범위(spatial scope)
측정 스케일	-연구 대상 전체를 구성하고 있는 기본 공간단위(spatial unit)의 크기 -관측지의 크기 / 공간 해상도(spatial resolution - sampling 몇 개?) / 밀도(공간단위 수 / 공간범위) -측정 스케일과 지리 스케일은 연동됨: 좁은 지리 스케일일수록 측정 스케일 작아지는 경향
작동 스케일	-공간적 프로세스(spatial process)가 작동하는 공간적 범위

-MAUP (modifiable areal unit problem, 공간단위 임의성의 문제)

MAUP	-연구에 사용되는 공간단위의 선정은 기본적으로 임의적이며, 연구의 (통계적) 결과는 선정된 공간단위와 체계적인 관련성을 가짐			
	-두 가지 효과			
	<table border="1"> <tr> <td>스케일 효과 $\rightarrow$</td><td>-측정 스케일의 차이에 기인한 효과 -측정 스케일이 커질수록 • 분산 감소 • 상관관계수/결정계수 증가 / 회귀계수 변화 • 공간적 자기상관 감소</td></tr> <tr> <td>구획 효과</td><td>-구획 방식의 차이에 기인한 효과 (같은 스케일 하에서도)</td></tr> </table>	스케일 효과 $\rightarrow$	-측정 스케일의 차이에 기인한 효과 -측정 스케일이 커질수록 • 분산 감소 • 상관관계수/결정계수 증가 / 회귀계수 변화 • 공간적 자기상관 감소	구획 효과
스케일 효과 $\rightarrow$	-측정 스케일의 차이에 기인한 효과 -측정 스케일이 커질수록 • 분산 감소 • 상관관계수/결정계수 증가 / 회귀계수 변화 • 공간적 자기상관 감소			
구획 효과	-구획 방식의 차이에 기인한 효과 (같은 스케일 하에서도)			

-MAUP을 해결할 수 있는 두 가지 방법 (?)

공간적 의존성(spatial dependence)

-토블러의 '지리(학)의 제1법칙': "모든 것은 다른 모든 것과 연관되어 있다. 그러나 가까이 있는 것은 멀리 떨어져 있는 것보다 더 많이 연관되어 있다." (1970)

-본원적인 지리적 프로세스: 공간적 효과(spatial effects) $\rightarrow$ 특정한 공간적 패턴 (군집/분산) 공간이 만들어내는 차이.

-정의: 공간단위 간의 지리적 근접성과 공간단위가 보유한 속성값 간의 수치적 유사성, 이 둘의 특정한 관련성

- 관측지 간의 공간적 유사성: 공간적 근접성(spatial proximity)
- 관측지 간의 수치적 유사성

-공간적 자기상관(spatial autocorrelation)

- auto-: 한 속성 내부('두 속성 간'이 아님)
- spatial correlation: 공간적으로 관련되어 있는 둘 간의 상관성(한 공간단위와 그 이웃) / 원변수와 공간적 파생변수(예) 주변 hexagon의 평균)의 상관성

양의 공간적 의존성 / 양의 공간적 자기상관	음의 공간적 의존성 / 음의 공간적 자기상관
-공간단위가 가까울수록 속성값이 비슷함	-공간단위가 가까울수록 속성값이 다름
-동화 프로세스, 인력, 파급효과(spillover effect)	-이화 프로세스, 척력, 역류효과(backwash effect)

★ 공간적 의존성의 통계학적 의미: 가장 기본적인 통계학적 가정의 위배!



① 독립관측가정 (assumption of independent observations)의 위배

- 한 공간단위에서의 관측이 인접 공간단위에서의 관측에 의존적임: 인접 공간단위 관측치를 추측하는 것에 합리성이 존재
- 정보의 손실과 중복
- 한 관측지가 보유한 정보의 양에서의 손실 (자기상관 ↑ ↓).
- 관측지들이 보유한 정보 간의 중복

→ 개체별 증가 가능성.

② 양의 공간적 의존성: 자유도의 하락 → 채택역 확대 → 귀무가설 기각을 위한 임계 기준 상승 → 제1종오류 가능성 증대

공간적 자기상관 정도	0	0.05	0.15	0.25	0.35	0.45	0.55	0.65	0.75	0.85
n=100일 때의 critical value	1.960	2.059	2.276	2.550	2.813	3.165	3.609	4.207	5.096	6.669

③ 음의 공간적 의존성: 정반대 (critical value 감소)

공간적 이질성 (spatial heterogeneity)

-정의: 개별 관측지나 하위 지역(인접 관측지의 연합)이 가지는 본질적인 특이성

- ① 표준 통계량(평균, 분산, 상관계수, 회귀계수 등)의 '지역적' 편차
- ② 공간적 의존성(예: 모런 통계량)의 지역적 편차 → "공간적 이질성은 공간적 의존성의 파생 개념" (Anselin & Getis, 1992)

lack of spatial uniformity = effects of spatial dependence

-공간적 이질성의 결과

① 동일모집단가정 (assumption of the same population)의 위배: 하위지역별로 통계적 속성이 매우 달라서 마치 여러 개의 모집단으로부터 생성된 표본이 조합된 것으로 여겨질 정도

② 국지적 통계량 (local statistics)의 의미 강화

→ 지리가중회귀분석 GWR

공간적 컨피그레이션 (spatial configuration)

-정의: 관측지간의 공간적(위상적) 관계 — em 2개에 관한?

-관련 개념

에어리어 데이터 & 그리드 데이터	-연접성(contiguity), 인접성(adjacency) → 이웃(neighborhood) → 루크 방식, 비숍 방식, 퀸 방식
지구통계학적 데이터 (포인트 패턴 데이터)	-이격성(separateness), 거리(distance) → 이웃(neighborhood)

-공간근접성행렬 (spatial proximity matrix, SPM, V)로 표현

SPM	-공간가중치행렬 (spatial weights matrix, W)이라고도 함 -관측지 간의 공간적 관계에 대한 수치적 요약 → 안 쓰이면 일반 통계 -연접성-기반 vs. 거리-기반
	-이항연접성행렬: 퀸 방식 (edges+vertices), 루크 방식 (edges) → 고차연접성 + cumulative • hexagon 구조로 생각: 섬의 문제 사라짐 Queen's case contiguity (edges and vertices) = 4 neighbours Rook's case contiguity (edges only) = 3 neighbours Queen's case contiguity Rook's case contiguity → 섬의 문제, (해 X) -역거리행렬: centroid 이용 -최근린 이웃 (nearest neighborhood): 가장 가까운 n개 이웃 → 실질적 이웃 • 장점: 모든 지역이 동일한 개수의 이웃 가짐 (섬의 문제 사라짐) • 단점: 정말 이웃인가? (거리성의 정도 질적으로 차이남) -임계거리 (critical distance) • 장점: 지역마다 이웃 개수 달라짐 (이격성 반영 - 조밀한 곳일수록 이웃 많음) • 단점: 기준을 얼마로 할 것인가? (어떤 곳은 이웃 없을 수도)

최근린 이웃	임계거리
-관련 이슈: 행-표준화(row-standardization) • 행별 합산값(이웃의 개수)으로 나눔 → 모든 행의 합산값 1이 되도록 • 확률론적 성격, 가중값의 특성 • 비대칭적 • “Row standardization is recommended whenever the distribution of your features is potentially biased due to sampling design or an imposed aggregation scheme.”	

3. SDA의 기법

3.1. 공간적 패턴 데이터 분석

-remark. 공간데이터의 3가지 속성: 위치, 속성, 공간관계 → point pattern data에서는 위치가 가장 중요

-포인트 패턴 데이터에서 공간적 변동의 본질: 해당 사건 발생 강도(intensity)의 공간적 다양성

-공간적 변동의 종류

군집 패턴 (clustered)	분산(규칙) 패턴 (regular)	무작위 패턴 (random)
-양의 공간적 자기상관	-음의 공간적 자기상관	-공간적 무자기상관

-공간적 변동의 원천 in point pattern data: 분해의 어려움 존재

1차 효과	밀도의 전역적 경향성 -절대적 위치가 중요 예 '좌하' → '우상': point 발생 확률 증가 낮아진다.
2차 효과	위치 간의 상호작용 -상대적 위치가 중요

→ only 1차/2차 효과만을 설명 가능...

3.1.1. 비주얼라이제이션

(공간적) 커널 밀도 추정

-점형 사건의 발생 강도(intensity)의 공간적 변동 시각화

• 모든 지점(그리드 셀)에서의 발생 강도(밀도) 값 추정 → 커널 밀도면(kernel density surface) 생성

• 포인트 패턴 데이터 → 그리드 데이터

단순 밀도 추정	$\hat{\lambda}(s) = \frac{\#(C(s,d))}{\pi d^2}$	-특정 지점 s(그리드 셀의 중심점)로부터 거리 d를 반경으로 하는 원 속에 포함 되는 포인트의 개수 / (원의 면적) → 거리에 따른 가중치의 적용 필요함
커널 밀도 추정	$\hat{\lambda}(s) = \sum_{i=1}^n \frac{1}{\tau^2} k\left(\frac{s-s_i}{\tau}\right)$	-τ: 탐색반경(bandwidth) -s - s _i : 커널의 중심점 s로부터 i번째 포인트 까지의 거리 ⇒ 반지름 -k(): 커널 함수 → 거리에 따른 가중치 결정 *4차 커널 함수의 경우: $k\left(\frac{d_i}{\tau}\right) = \begin{cases} \frac{3}{\pi} \left[1 - \left(\frac{d_i}{\tau}\right)^2\right]^2 & \text{for } d_i \leq \tau \\ 0 & \text{otherwise} \end{cases}$ → $\hat{\lambda}(s) = \sum_{d_i \leq \tau} \frac{3}{\pi \tau^2} \left[1 - \left(\frac{d_i}{\tau}\right)^2\right]^2$

-탐색반경의 차이: bandwidth 커질수록 공간적 완만성(continuous), 공간적 평활도(smoothness) 증가

(전체적으로 값이 비슷해짐 & 값은 한 차를 차질 해짐).

3.1.2. 공간적 기술통계

-중심성: 대표 지점이 어디인가?

평균지점 (mean center)	$(\bar{X}_c, \bar{Y}_c) = \left(\frac{1}{n} \sum X_i, \frac{1}{n} \sum Y_i\right)$	-X 좌표값들의 평균값, Y 좌표값들의 평균값 -모든 지점까지의 거리의 제곱의 합을 최소화하는 지점 이 된다. → $(\bar{X}_c, \bar{Y}_c) : \min \{ \sum (X_i - \bar{X}_c)^2 + \sum (Y_i - \bar{Y}_c)^2 \}$
-----------------------	--	---

최근린분석 (nearest neighbor analysis)	-방격분석의 한계 - 방격이 존재하지 않은 연속체 • 방격의 크기(측정 scale)에 따라 결과가 달라짐 → MAUP • 각 cell 내 개수만 생각 → cell 내부에 나타나는 패턴에 대해 고려하지 않음 • 측정지의 공간적 정보(cell 간의 공간관계) 사용하지 않음 → '공간의 탈을 쓴 비공간'	① $\begin{bmatrix} \cdot & \cdot \\ \cdot & \cdot \end{bmatrix} = \begin{bmatrix} \cdot & \cdot \\ \cdot & \cdot \end{bmatrix}$ cell 내 패턴/정보 무시. ② $\begin{bmatrix} \cdot & \cdot \\ \cdot & \cdot \end{bmatrix}$ 정보 손실의 위험.
	-모든 지점에서 가장 가까운 지점까지의 거리 → 평균 최근린 거리(ANND) 산출 • $ANND_O = \frac{\sum \min d_i}{n}$ = <u>평균 최근린 지점까지의 거리</u> • $ANND_E = \frac{1}{2\sqrt{n/A}} = \frac{1}{2\sqrt{\lambda}}$ (A = 연구 지역 전체 면적, λ = 단위 면적 당 개수) → CSR 하에서 기대되는 평균 최근린 거리.	
	-지표 $R = ANND_O / ANND_E$ -R > 1: 기대되는 평균 최근린 거리보다 충분히 큼 → 분산 패턴 -R = 1: CSR -R < 1: 기대되는 평균 최근린 거리보다 충분히 작음 → 군집 패턴	→ CSR 하에서 기대되는 평균 최근린 거리. 작은 값이면 군집.
	-가설 검정 -귀무가설: ($ANND_O = ANND_E$) 주어진 포인트 패턴 데이터는 통계적으로 유의미한 수준의 비무작위적 패턴을 보이지 않는다. -대립가설: • $ANND_O \neq ANND_E$: 주어진 포인트 패턴 데이터는 통계적으로 유의미한 비무작위 패턴을 보인다. • $ANND_O > ANND_E$: 주어진 포인트 패턴 데이터는 통계적으로 유의미한 분산 패턴을 보인다. • $ANND_O < ANND_E$: 주어진 포인트 패턴 데이터는 통계적으로 유의미한 군집 패턴을 보인다. -측정통계량: $ANND_O$ • 표본분포: 정규분포 sampling dist. -검정통계량: $Z = \frac{ANND_O - ANND_E}{SE_E}$ (표준화) • $SE_E = \sqrt{\frac{(4-\pi)A}{4\pi n^2}} = \frac{0.26136}{\sqrt{n\lambda}} = \frac{0.26136}{\sqrt{n^2/A}}$ -고차 평균 최근린 거리에 대한 가설검정 • $ANND_E(k) = \frac{(2k)! \times k}{(2^k \times k!)^2} \frac{1}{\sqrt{\lambda}}$, $SE_E = \sqrt{\frac{k}{\pi\lambda} - (ANND_E(k))^2} \frac{1}{\sqrt{n}}$	

3.2. 에어리어 데이터 분석

3.2.1. 개요

-에어리어 데이터의 본질적 특성

개체	-불규칙 테셀레이션(irregular tessellation): 다수의 단일하지 않은 역형 개체로 구성 -MECE(mutually exclusive and collectively exhaustive, 상호배제와 전체포괄): 서로 중첩되지 않으며, 모두 합쳤을 때 전체 지역을 완전히 구성 -표집 폴리곤(sampling polygons)의 역할: 관측이나 데이터 수집이 이루어지는 '공간단위' 예) 센서스의 집계구, 행정구역	
	-명목/서열/등간/비율 척도	
속성	공간적으로 외연적인 변수 -이산적 속성: 비도, 총합 -도형표현도 e.g. 인구	공간적으로 내포적인 변수 -연속적 속성: 평균, 비중, 비 -단계구분도 e.g. 화력발전

-기법의 분류

공간적 자기상관 통계량	-측정통계량 + 가설검정 절차	
	전역적 차원의 공간적 자기상관 정도 측정	국지적 차원의 공간적 자기상관 정도 측정
	-명목척도: 조인-카운트 통계량 -등간/비율척도(연속): 모런/기어리 통계량	-특이한 패턴 탐지: 공간 클러스터, 공간 특이점 -LISA: 국지적 모런/기어리, 게티스-오드 통계량

remark. 공간이 이질성.

	-특징: (거의) -1 ~ 1의 값을 가짐 -해석 - 기댓값보다 큰 경우(양수): 양의 공간적 자기상관 - 기댓값보다 작은 경우(음수): 음의 공간적 자기상관 -행 표준화 시 W가 달라지므로 값에 차이가 발생 -가설 검정: Z-검정(randomization assumption의 경우) Z-검정 -측정통계량: I -표본 분포: normal distribution $E(I) = \frac{-1}{n-1}$ $Var(I) = \frac{n^2(n-1)S_1 - n(n-1)S_2 + 2(n-2)S_0^2}{S_0^2(n+1)(n-1)^2}$ $\Rightarrow S_0 = \sum_i \sum_j w_{ij} / S_1 = \frac{1}{2} \sum_i \sum_j (w_{ij} + w_{ji})^2 / S_2 = \sum_i (w_i + w_i)^2$ -검정통계량: $Z(I) = \frac{I - E(I)}{\sqrt{Var(I)}}$ -귀무가설 기각: 주어진 패턴은 유의미한 "공간적 자기상관"을 만드는 spatial stochastic process에 의해 만들어졌다. (1, 2차 효과 결합)
기여리 통계량	-수식: $c = \frac{n-1}{2 \sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$ -차이 제곱. -행표준화: $c = \frac{n-1}{2n^2} \sum_i \sum_j w_{ij} (z_i - \bar{z})(z_j - \bar{z})$ -해석 - 기댓값은 1 $0 \leq c < 1$: 양의 공간적 자기상관 $1 < c < 2$: 음의 공간적 자기상관 -가설 검정: Z-검정(randomization assumption의 경우) Z-검정 -측정통계량: c -표본 분포: normal distribution $E(c) = 1$ $Var(c) = \frac{(2S_1 + S_2)(n-1) - 4S_0^2}{2(n+1)S_0^2}$ $\Rightarrow S_0 = \sum_i \sum_j w_{ij}, S_1 = \frac{1}{2} \sum_i \sum_j (w_{ij} + w_{ji})^2, S_2 = \sum_i (w_i + w_i)^2$ -검정통계량: $Z(I) = \frac{I - E(I)}{\sqrt{Var(I)}}$ -귀무가설 기각: 주어진 패턴은 유의미한 공간적 자기상관을 만드는 spatial stochastic process에 의해 만들어졌다. (1, 2차 효과 결합)

육각형 그리드 데이터의 경우: 모런 통계량의 최솟값은 -10이 아님 $\Rightarrow S^$
 기여리 통계량의 최솟값은 0 아님..

3.2.3. 공간적 자기상관 통계량: 국지적 분석

-국지적 공간연관성 지표(local indicators of spatial association, LISA) (Luc Anselin)

-국지적 통계량의 평균은 전역적 통계량과 동일 $\Rightarrow \bar{I} = \frac{1}{n} \sum_i I_i$ -기여리, 모런.

-종류

국지적 모런 통계량	-수식: $I_i = \frac{n^2}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$ -행표준화 시: $I_i = \frac{\sum_i (x_i - \bar{x}) \sum_j w_{ij} (x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2 / n} = \frac{\sum_i (x_i - \bar{x}) \sum_j w_{ij} (x_j - \bar{x})}{\sqrt{\sum_i (x_i - \bar{x})^2 / n} \sqrt{\sum_i (x_i - \bar{x})^2 / n}} = z_i \sum_j w_{ij} z_j = z_i \tilde{z}_i$
-------------------	--

	☐ $I = \frac{1}{n} \sum_i I_i$ -해석 • 기댓값보다 큰 경우(양수): 양의 공간적 자기상관 } <i>공간 cluster detection (global 자기상관이 양수냐 아니냐 하?)</i> • 기댓값보다 작은 경우(음수): 음의 공간적 자기상관 } <i>outlier</i> -가설 검정: Z-검정(randomization assumption의 경우) -측정통계량: I -표본 분포: normal distribution • $E(I_i) = \frac{-1}{n-1} W_i$ → ? • $Var(I_i) = \frac{w_i^{(2)}(n-b_2)}{n-1} + \frac{(w_i^2 - w_i^{(2)})(2b_2-n)}{(n-1)(n-2)} - [E(I_i)]^2$ -검정통계량: $Z(I) = \frac{I - E(I_i)}{\sqrt{Var(I_i)}}$ <i>hot spot인지도 알 수 있다. → global 데이터 봐야 함.</i> ☐ 유의한 만큼 크거나 작으면 spatial cluster & spatial outlier
--	---

게티스-오드 통계량	-원 수식: $G_i = \frac{\sum_j w_{ij} x_j}{\sum_j x_j}$ -수정 수식: $G_i^* = \frac{\sum_j w_{ij} x_j - W_i \bar{x}}{s \sqrt{(n S_{ii}^* - W_i^{*2}) / (n-1)}} = \frac{\tilde{z}_i^*}{\sqrt{(\frac{n}{n_i^*} - 1) / (n-1)}}$ ($\tilde{z}_i$: i번째 에어리어와 이웃한 것들과 연결해 있는 에어리어들의 (z-값의 평균)) -의미 • 양의 공간적 자기상관만 측정 가능 <i>H-H</i> • 양수: 평균보다 큰 값들의 응집 → hot spot • 음수: 평균보다 낮은 값들의 응집 → cold spot <i>행렬로 $\sim N(0,1)$</i> <i>≠ 음의 자기상관!</i>
------------	---

-국지적 모런 통계량을 이용한 ESDA 기법

<i>작은 값</i> 국지적 모런 지도	-국지적 모런 통계값을 속성값으로 하여 제작한 단계구분도
	-x축: 원 데이터의 표준점수 (z_i) -y축: 연결해 있는 에어리어들의 표준점수의 평균값 ($\tilde{z}_i$) 회귀식의 기울기: 전역적 모런 통계량 ($\tilde{z}_i$를 종속변수로, z_i를 독립변수로 둔 회귀식의 기울기) ☐ “공간적 자기상관은 결국 z_i와 $\tilde{z}_i$ 간의 상관관계” -4 사분면 ☐ 네 종류의 공간연관성 유형과 연결 • H-H: 평균보다 높은 값이 평균보다 높은 값에 둘러싸여 있음 • H-L: 평균보다 높은 값이 평균보다 낮은 값에 둘러싸여 있음 • L-H: 평균보다 낮은 값이 평균보다 높은 값에 둘러싸여 있음 • L-L: 평균보다 낮은 값이 평균보다 낮은 값에 둘러싸여 있음 <i>$r = \frac{\sum z_i \tilde{z}_i}{\sum z_i^2 \sum \tilde{z}_i^2} = \frac{\sum (z_i - \bar{z})(\tilde{z}_i - \bar{\tilde{z}})}{n} = \frac{\sum (z_i - \bar{z})(z_i - \bar{z})}{n} = \frac{\sum (z_i - \bar{z})^2}{n}$</i> <i>($z_i, \tilde{z}_i \sim N(0,1)$)</i>
	모런 산포도 지도 -네 종류의 공간연관성 유형을 나타낸 정성적 주제도
	모런 확률 지도 -유의성 검정 결과 도출된 p-값(유의확률)에 대한 단계구분도
	-통계적으로 유의미한 국지적 패턴을 나타낸 지도 -모런 산포도 지도와 모런 확률 지도의 결합 공간 클러스터 (spatial cluster) -유의미하게 유사한 값을 보이는 공간단위들의 응집체 ☐ 양의 공간적 자기상관 -H-H, L-L 중 통계적으로 유의미한 공간단위들의 응집체 공간 특이점 (spatial outlier) -주변 공간단위와 유의미하게 유사한 값을 보이는 공간단위들의 응집체 ☐ 양의 공간적 자기상관 -H-L, L-H 중 통계적으로 유의미한 공간단위들의 응집체

-게티스-오드 통계량을 이용한 ESDA 기법

게티스-오드 통계량 지도	-게티스-오드 통계값을 속성값으로 하여 제작한 단계구분도 -양수: 평균보다 큰 값들의 응집 / 음수: 평균보다 작은 값들의 응집
---------------	---

-GWR(지리가중회귀분석, geographically weighted regression)

- 회귀분석의 모든 통계량(회귀계수, 결정계수 등)이 보여주는 공간적 이질성의 문제 remark. 첫 번째 공간적 이질성
- 개념: 모든 데이터포인트에 대해 독자적인 회귀분석을 행함
- “인과성의 공간적 변동 (spatial variation of causalities)”: 인과성이 지역마다 다름

*remark. OLS

$$-Y_i = \beta_0 + \sum_{j=1}^{k-1} \beta_j X_{ij} + \epsilon_i \Rightarrow y = X\beta + \epsilon \text{ where } \beta = [\beta_0 \beta_1 \dots \beta_{k-1}]^T$$

$$-Y_i = \beta_{i0} + \sum_{j=1}^{k-1} \beta_{ij} X_{ij} + \epsilon_i \Rightarrow y = (X \otimes B)1 + \epsilon \text{ where } B = \begin{bmatrix} \beta_{10} & \beta_{11} & \dots & \beta_{1,k-1} \\ \beta_{20} & \beta_{21} & \dots & \beta_{2,k-1} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{n0} & \beta_{n1} & \dots & \beta_{n,k-1} \end{bmatrix}$$

- n개의 포인트 각각에 대해 n개의 회귀식 적합

-지리적 가중값의 결정: 가우스 커널(Gaussian kernel): $w_{ij} = \exp[-\frac{1}{2}(d_{ij}/\tau)^2]$


- d_{ij} : i번째 공간단위에서 j번째 공간단위까지의 거리 (centroid 간 거리)

- τ : 탐색 반경


-가중 OLS 추정: $\hat{\beta}_i = (X^T W_i X)^{-1} X^T W_i y = [\beta_{i0} \beta_{i1} \dots \beta_{i,k-1}]^T \Rightarrow$ 회귀계수별로 단계구분도로 표현

국지적
공간적
회귀분석

GWR



- 회귀계수의 spatial autocorrelation 높음 (:: bandwidth 계산한 뒤 그 지역 회귀분석) $\Rightarrow$ 무관하게 분석할 수 없음
- 두 독립변수 모두 양의 관련성 + OLS 회귀계수(평균적으로 RNI에 영향을 미친 정도)를 midpoint로 하여 비교
- ㉠ 수도권: TFR이 1단위 증가했을 때의 RNI 증가 폭이 평균보다 큼 (:: P_F 높음) / P_F 1단위 증가했을 때 RNI 증가폭이 평균보다 작음 $\Rightarrow$ (다른 지역에 비해) TFR이 더 중요



- OLS 회귀분석 했을 때의 잔차와 비교 - 유사해 보이나...
- 비판: 잔차의 자기상관 없어진다는 근거 없음 / 개별 지역 값의 의미?

↳ 실제로 자원가?

	-multi-scale GWR: bandwidth의 크기(operational scale, 공간적 자기상관이 벌어지는 범역)이 독립 변수마다 달라짐 -Daniel A. Griffith: 고유벡터공간필터링 접근법 개발 (고유벡터를 이용, 상관분석에 투입된 두 변수 필터링 → 평균+공통+특수+잔차로 공간적 패턴 요소분해 → 잔차 간의 상관계수 = 공간필터 상관계수) → 공간적 자기상관을 제거.
--	---

3.3. 지구통계학적 데이터 분석

3.3.1. 지구통계학적 데이터의 본질적 특징

-지구통계학적 데이터

개체	-연구 대상 지역 내부에 존재하는 다수의 고정된 위치를 갖는 지점들 -'관측 지점' → 표집 포인트(sampling point) • 관측이나 데이터 수집이 이루어지는 기본 위치 • 주로 정교하게 디자인된 표집 네트워크를 구성 -종류 • 실측 지점: 기상 관측소, 자원 시추지점 등 실질적인 관측이 이루어지는 지점 - 대부분. • 개념 지점: 역형 개체의 센트로이드와 같은 편의상의 대표 지점
속성	-명목/서열/등간/비율 척도 -주로 등간/비율 척도 중 연속적(실수형) 속성 → 공간적으로 내포적인 속성, "공간적으로 연속적인 데이터"

-공간적 추정(spatial estimation)의 필연적 개념

- 관측 지점의 속성값((S, z))을 이용해 연구 지역 내 다른 지점의 속성값(z)을 추측
- ⑨ 공간적 인터플레이션 (spatial interpolation)

3.3.2. 공간적 인터플레이션

-정의: 관측 지점의 속성값을 바탕으로 연구 대상 지역 내 다른 모든 지점의 속성값을 추정하는 과정

지구통계학적 데이터 → 그리드 데이터 (GIS: 벡터 데이터(점형) → 래스터 데이터(실수형))

-기법의 분류

전역적 (global)	-특정 지점의 값을 추정하기 위해 모든 관측 지점의 값을 등가적으로 사용 -추정 지점과 관계없이 동일한 방식으로 관측 지점의 속성값을 사용
국지적 (local)	-특정 지점의 값을 추정하기 위해 특정한(가까이에 위치한) 관측 지점의 속성값만을 사용 → 모든 표집 지점의 속성값을 추정 지점과의 공간적 관계에 의거하여 부등가적으로 사용 -추정 지점에 따라 상이한 방식으로 관측 지점의 속성값을 사용

-기법의 분류 2

결정론적 (deterministic)	-추정값의 오차한계가 제공되지 않음
확률론적 (stochastic)	-추정값의 오차한계가 제공됨 → 오차한계가 공간적으로 다양

-기법의 분류 3, 4

일치적 (exact)	-관측 지점에서의 원속성값과 추정값과의 일치성	완변적 (smooth)	-추정값의 공간적 분포 특성
불일치적 (inexact)		급변적 (abrupt)	

-기법의 종류

	전역적	국지적
결정론적	-전역적 경향면법: 불일치적 / 완변적	-티센 폴리곤법: 일치적 / 급변적
확률론적		-역거리가중법: 불일치적 / 완변적 -크리깅: 일치적 / 완변적

-경향면법 (trend surface method)

원리	-관측 지점의 좌표값을 독립변수로, 관측값을 종속변수로 둔 다항 회귀분석의 실행 -도출된 회귀식에 추정 지점의 좌표값을 대입하여 추정값을 계산	
종류	-전역적 경향면법 -국지적 경향면법: 국지가중 회귀분석 (locally weighted regression, LOESS) → GWR(독립변수를 좌표값으로?)을 이용한 interpolation	
특징 (전역적)	전역적	-모든 관측값을 등가적으로 이용: 모든 추정 지점에 대해 동일
	결정론적	-오차 한계 계산 가능 but 추정 지점간 차이 없음 ?
	불일치적	-원관측값과 추정값의 불일치
	완변적	-가장 완변적

국지적: 결정론적, 불일치적, 완변적.

p-차 경향면	-차수에 따른 항의 개수: $P = (p+1)(p+2)/2$
	예 1차: $z = b_0 + b_1x + b_2y$
	예 2차: $z = b_0 + b_1x + b_2y + b_3x^2 + b_4xy + b_5y^2$

-티센 폴리곤법

원리	-티센 폴리곤(Thissen Polygon) 개념을 공간적 인터폴레이션에 적용	
	티센 폴리곤	-거리에 기반하여 설정한, 개별 포인트의 포섭영역 -개별 티센 폴리곤 내의 모든 위치는 다른 어떤 포인트보다 그 폴리곤 내의 해당 포인트와 가장 가까움 <i>↳ 티센 폴리곤 내 포인트 = 삼중지점</i>
-각 추정 지점(그리드 셀)에 대해 최근린 관측 지점 확인 → 그 최근린 지점의 관측값을 해당 추정 지점(그리드 셀)에 할당: 최근린 관측 지점이 동일한 추정 지점은 동일한 추정값 가짐		
특징	국지적	-최근린 관측 지점의 관측값만을 이용
	결정론적	-오차 한계 계산 불가능
	일치적	-원관측값과 추정값 일치
	급변적	-티센 폴리곤 간에 단절 존재 <i>티센 폴리곤에서 점프한다.</i>

-역거리가중법

원리	-공간적 자기상관 개념을 공간적 인터폴레이션에 정교하게 적용	
	- 각 추정 지점에 대해 관측 지점까지의 거리를 계산 → 거리가 가까울수록 더 많이 참조하여 추정값 도출 - 추정 지점별로 관측 지점을 상이하게 참조	
특징	-추정 과정	
	(1) 각 추정 지점별로 이웃 설정 (2) 역거리 함수를 통해 개별 이웃에 대한 가중값 도출 (3) 가중값과 관측값 곱한 후 합산하여 추정값 도출	
	국지적	-추정 지점별로 서로 다른 방식으로 관측값을 이용
	결정론적	-오차 한계 계산 불가능
	불일치적	-원관측값과 추정값 불일치
	완변적	-거리계수가 작을수록 완변적 (경향면법보다는 덜 완변적)

이웃의 정의	최근린개수법	고정반경법
	-사전에 결정된 개수 만큼의 이웃을 선정 -모든 추정 지점이 동일한 수의 이웃을 가짐 -추정 지점별로 탐색반경이 다양할 수 있음	-사전에 결정된 탐색반경에 의거해 이웃을 선정 -모든 추정 지점에 동일한 크기의 탐색반경을 가짐 -추정 지점별로 이웃의 개수가 다양할 수 있음
→ 하이브리드 방법: - 최근린개수법에 기반하지만 최대 탐색반경을 설정 - 고정반경법에 기반하지만 최소 최근린개수를 설정		

추정

$\hat{z}_0 = \sum_i \lambda_i z_i$: (이웃 관측 지점의 가중값 X 관측값)의 합 = *가중값*

- $\sum_i \lambda_i = 1$: 가중값의 합은 1

- $\lambda_i = \frac{1}{d_i^\beta} / \sum_i \frac{1}{d_i^\beta}$: 가중값은 특정한 역거리 함수로 결정 (β : 거리계수, 보통 2)

- β 가 커질수록 거리의 효과가 커지며, 작을수록 더 *완변적* *↗️* *peak가 생긴다.*

Diagram illustrating the weighted average calculation for a central point (red dot) based on three surrounding points (blue dots):

- Point A: Value = 100, Distance = 4
- Point B: Value = 160, Distance = 3
- Point C: Value = 200, Distance = 2

The final weighted average calculation is shown in a box: $15 + 42 + 118 = 175$.

	역거리	가중값	계산
A	$1/4^2 = 0.0625$	$0.0625/0.4236 = 0.15$	$100 \times 0.15 = 15$
B	$1/3^2 = 0.1111$	$0.1111/0.4236 = 0.26$	$160 \times 0.26 = 42$
C	$1/2^2 = 0.2500$	$0.2500/0.4236 = 0.59$	$200 \times 0.59 = 118$
	$\Sigma = 0.4236$	$\Sigma = 1.00$	

단점	- 측정값 간의 공간적 자기상관 고려하지 않음 (cf. 추정-측정 지점 간의 자기상관은 고려) • 같은 거리(2)의 information D(200) 추가 → but D의 위치와 상관없이 같은 weighting • 실제로는 가중값 더 낮아지거나 커져야 함
----	--

3.3.3. 크리깅

-공간적 자기상관에 대한 가정

- 양의 공간적 자기상관만 고려
- 정상성(stationarity) 가정: 공간적 자기상관의 양상(정도)은 절대적 위치와는 무관 → 어디에 있건 다른 포인트와의 상대적 위치(거리/방향)에만 의존
- 등방성(거리) / 이방성(거리&방향)
- 공간적 자기상관의 탐색과 측정 by 그래프
- 베리오그램: 베리오그램 클라우드, (세미)베리오그램
- 코베리오그램

$Y = SAC \text{ 강도}$

→ points: pair 차등 모든 쌍.

$X = H2I$

(세미)베리오그램	- 거리에 따른 세미베리언스(이질성)의 증가 (양의 공간적 자기상관 감소) $\hat{\gamma}(h) = \frac{1}{2 \cdot n(h)} \sum_h (y_i - y_j)^2$ • $\hat{\gamma}(h) = \frac{1}{2 \cdot n(h)} \sum_h (y_i - y_j)^2$ - 등방성 $\gamma(h) = \sigma^2 - C(h)$	Variogram
코베리오그램	- 거리에 따른 코베리언스(유사성)의 감소 (양의 공간적 자기상관 감소) $\hat{C}(h) = \frac{1}{n(h)} \sum_h (y_i - \bar{y})(y_j - \bar{y})$ • $\hat{C}(h) = \frac{1}{n(h)} \sum_h (y_i - \bar{y})(y_j - \bar{y})$ $C(h) = \sigma^2 - \gamma(h)$	Covariogram

-세미베리오그램 모델링

세미베리오그램 모델링

- 관측 지점 간 거리 측정
- 관측 지점 간 값 차이의 제곱값 (혹은 그 절반) 계산
- 거리구간(distance bin) 설정
- 거리구간별 평균값 계산
- 곡선 추정: (주로) 비선형 회귀분석 → spherical(구형), exponential(지수) 모델
- 모델의 요소

레인지(range)	- 공간적 자기상관의 임계거리 (r) - 가장 짧은 (sampling의 결과...) - 이 이상의 거리에서는 공간적 자기상관이 존재하지 않음
실(sill)	- 공간적 자기상관의 임계거리에서의 이질성 정도(세미베리언스 값) - 최대값은 σ^2 (= 변수가 가진 variance의 값)
너겟(nugget)	- 매우 가까운 거리에서의 이질성 정도(세미베리언스 값)

- 기본 모형: $\gamma(h) = \sigma^2(1 - e^{-3h/r})$ (→ $C(h)$ 구하는 데 활용)





-크리깅의 종류

단순 크리깅	일반 크리깅
- 1차 효과(전역적 트렌드, 기댓값)와 2차 효과(국지적 상호작용, 잔차)의 분리 - 1차 효과에 대한 가정 • 동질적 1차 효과: 모든 지점의 기댓값 동일 (=평균) → 1차 효과 없다고 말하는 것과 같음 • 이질적 1차 효과: 모든 지점의 기댓값 상이	- 1차 효과가 2차 효과의 추정 과정에 내재됨: 동시 추정 - 종류 • 오디네리 크리깅: 동질적 1차 효과 가정 • 유니버설 크리깅: 이질적 1차 효과 가정

-단순 크리깅

특징	-국지적, 확률론적, 일차적, 완전적
전제	- 1차 효과에 대한 가정: 평균값 (동질적 1차 효과) / 전역적 경향면 (이질적 1차 효과) - 2차 효과의 정식화: 데이터로부터 (세미)베리오그램 도출

가중치

모형 설정	$Y(s) = \mu(s) + U(s)$: 1차 효과(기댓값) + 2차 효과(잔차) $\hat{Y}(s) = \mu(s) + \hat{U}(s)$: 전체 추정 = 1차 효과 + 2차 효과에 대한 추정 $\hat{U}(s) = \sum_i \lambda_i(s) U(s_i)$: 추정 지점의 i번째 이웃에 대한 <u>가중값</u> $\times$ i번째 이웃의 잔차값 (= 실제 데이터 - 기댓값)	
추정	-기본 모델: $\hat{U}(s) = \sum_i \lambda_i(s) U(s_i)$ = <u>코베리언스</u> $\times$ <u>벡터</u> (= 추정-잔차 지점 간 거리). • 가중치 추정: $\hat{\lambda}(s) = C^{-1}c(s)$ $\Rightarrow$ 2차 효과 추정: $\hat{U}(s) = \hat{\lambda}(s)^T u = c^T(s) C^{-1} u$ -분산의 추정: $Var[\hat{U}(s)] = \sigma_e^2 = \sigma^2 - \underline{c^T(s) C^{-1} c(s)}$ -최종 추정값: $\hat{Y}(s) = \mu(s) + \hat{U}(s)$ -신뢰구간: $\hat{Y}(s) \pm 1.96 \times \sigma_e$	
예	• $y = \begin{bmatrix} 122.0 \\ 183.0 \\ 148.0 \\ 160.0 \\ 176.0 \end{bmatrix}, \mu = 160.37$ <u>MCs</u> • $u = \begin{bmatrix} -38.37 \\ 22.63 \\ -12.37 \\ -0.37 \\ 15.63 \end{bmatrix}$ 	• $\hat{\gamma}(h) = 20(1 - e^{-3h/100})$ • $C(h) = \sigma^2 - \gamma(h)$ • $\hat{C}(h) = 20e^{-3h/100}$ $\Rightarrow$ 베리오그램 모델링
	• $D = \begin{bmatrix} 0 & d_{12} & d_{13} & d_{14} & d_{15} \\ d_{21} & 0 & d_{23} & d_{24} & d_{25} \\ d_{31} & d_{32} & 0 & d_{34} & d_{35} \\ d_{41} & d_{42} & d_{43} & 0 & d_{45} \\ d_{51} & d_{52} & d_{53} & d_{54} & 0 \end{bmatrix} \rightarrow C = \begin{bmatrix} 20.00 & 4.571 & 3.970 & 2.828 & 3.225 \\ 4.571 & 20.00 & 5.970 & 3.739 & 1.086 \\ 3.970 & 5.970 & 20.00 & 12.45 & 2.300 \\ 2.828 & 3.739 & 12.45 & 20.00 & 2.479 \\ 3.228 & 1.085 & 2.300 & 2.479 & 20.00 \end{bmatrix}$ • $d(s) = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ d_4 \\ d_5 \end{bmatrix} \rightarrow c(s) = \begin{bmatrix} 6.895 \\ 5.032 \\ 10.15 \\ 8.083 \\ 4.079 \end{bmatrix}$ $\hat{C}(h) = 20e^{-3h/100}$	• 가중값 벡터 • $\hat{\lambda}(s) = \underline{C^{-1}c(s)} = \begin{bmatrix} 0.225 \\ 0.066 \\ 0.351 \\ 0.128 \\ 0.107 \end{bmatrix}$ • 최종 추정 • $\hat{U}(s) = \hat{\lambda}(s)^T u = -9.86$ $\quad (0.225 \times -38.37) + (0.066 \times 22.63) + \dots + (0.107 \times 15.63)$ • $\hat{Y}(s) = \mu(s) + \hat{U}(s) = 160.37 - 9.86 = 150.05$ • $\sigma_e^2 = \sigma^2 - c^T(s) C^{-1} c(s) = 13.08$ • $150.05 \pm 1.960 \times \sqrt{13.08} = 150.05 \pm 7.09$
결과 해석	-IDW는 추정-관측 지점간 공간적 자기상관($c(s)$)만을 고려 -크리깅은 <u>관측 지점간</u> / <u>추정-관측 지점간</u> 모두 고려 $\Rightarrow$ '신선, independent, unique'한 정보에 더 큰 가중치 -지점에 따라 오차한계 달라짐     $\hat{Y}(s)$ 예측값을 표준화 ↑	


*관련 통계 개념 정리

1.2. 확률과 확률분포

표본공간	-모든 발생 가능한 사건 혹은 사상의 집합
확률변수	-표본공간으로부터 정의되는 임의의 실수 값들의 집합
확률분포	-확률변수의 특정한 값이나 특정한 구간에 포함되는 값이 발생할 가능성의 변동 $\rightarrow$ 합은 1
이항분포	-기대 사건의 발생 확률 $p \rightarrow n$ 번의 독립 시행 중 x 번의 기대 사건이 발생할 확률의 분포 -확률질량함수: $P(X=x) = \binom{n}{x} p^x q^{n-x}$ $-\mu = np, \sigma^2 = np(1-p)$
포아송분포	-일정한 단위공간/시간 내에서 특정 사건이 무작위로 발생할 때 그 사건이 발생할 횟수와 그에 대응하는 확률의 분포 <i>discrete</i> -확률질량함수: $P(X=x) = \frac{e^{-\lambda} \lambda^x}{x!}$ (λ = 단위시간/공간 당 특정 사건의 발생 빈도) $-\mu = \lambda, \sigma^2 = \lambda$
정규분포	-확률밀도함수: $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$ $-P(\mu - 1.645\sigma \leq X \leq \mu + 1.645\sigma) \approx 0.90$ $-P(\mu - 1.960\sigma \leq X \leq \mu + 1.960\sigma) \approx 0.95$ $-P(\mu - 2.576\sigma \leq X \leq \mu + 2.576\sigma) \approx 0.99$
표준정규분포	-표준화: $z_i = \frac{x_i - \mu}{\sigma}$ $-P(-1.645 \leq Z \leq 1.645) \approx 0.90$ $-P(-1.960 \leq Z \leq 1.960) \approx 0.95$ $-P(-2.576 \leq Z \leq 2.576) \approx 0.99$

1.3. 표본분포와 모수추정

모집단	-수치적 속성을 갖는 개체들의 집합
표본	-대표성을 보유한 모집단의 하위집합
모수	-모집단의 특성을 나타내는 양적인 측도
통계량	-표본의 특성을 나타내는 양적인 측도
모수추정	-표본의 통계량으로부터 모집단의 모수를 추측하는 것
세 가지 (확률)분포	-모집단의 분포: 종종 이론적 확률분포 가정 -표본의 분포: 경험적 확률분포 -표본분포: 표본통계량의 확률분포 $\rightarrow$ 이론적 확률분포 (많은 경우, 정규분포) • 모집단에서 동일한 크기로 추출할 수 있는 가능한 모든 표본들을 추출 $\rightarrow$ 각 표본으로부터 동일한 통계량을 계산했을 때 그 표본 통계량들이 나타내는 확률분포
중심극한정리	-표본이 충분히 크면 모집단의 분포 모양과는 상관없이 • 표본평균의 분포 $\approx$ 정규분포 • 표본평균의 평균 = 모집단의 평균 • 표준편차 = $\sigma/\sqrt{n}$ -모집단에서 한 표본을 추출해 평균을 구했을 때 • 그 표본평균이 특정한 구간에 놓일 확률 = 그 표본평균으로부터 특정한 구간에 모평균이 놓일 확률 • $P(\mu - 1.960\sigma_{\bar{X}} \leq \bar{X} \leq \mu + 1.960\sigma_{\bar{X}}) = P(\bar{X} - 1.960\sigma_{\bar{X}} \leq \mu \leq \bar{X} + 1.960\sigma_{\bar{X}}) \approx 0.95$
신뢰수준, 신뢰구간	-90% 신뢰구간 • 10개의 표본 중 1개의 표본에서 구해진 구간 속에는 모집단의 평균이 포함되지 않음 • 한 표본평균으로부터 구해진 '구간' 속에 모평균이 존재한다는 것을 90% 신뢰 -신뢰수준이 높을수록 신뢰구간 넓음 -(동일한 신뢰수준일 경우) 표본 크기가 클수록 신뢰구간 좁음
모수추정	-표본통계량을 이용해 모집단의 모수에 대한 추측값을 제시하고 그것의 오차한계를 제시하는 과정 -점추정 + 구간추정 예) 모평균 추정



	- 표본분포: $\bar{X} \sim N(\mu, \sigma^2/n)$ - 점추정, 표본오차 추정: $\hat{\mu}_{\bar{X}} = \bar{X}, \hat{\sigma}_{\bar{X}} = s/\sqrt{n}$ - 구간추정: $\bar{X} - Z_{CL}\hat{\sigma}_{\bar{X}} \leq \mu \leq \bar{X} + Z_{CL}\hat{\sigma}_{\bar{X}}$
임계값	-95% 신뢰수준: 1.96
표본오차	-임계값 X 표준오차(= 표본 통계량의 표준편차), a.k.a. 오차한계
t-분포	-표본의 크기가 30 이하일 때 $\rightarrow$ 표본분포로 가정 (모집단은 정규분포 가정 - 사실 아닐 때도 있지만..) -자유도 = 표본의 개수 - 1 - 자유도 커질수록 정규분포에 근사 - 자유도 낮을수록 정규분포의 임계값에 비해 큼 $\rightarrow P(t \geq 1.960) > P(Z \geq 1.960)$, 더 넓은 신뢰구간

1.4. 가설검정

가설검정	-설정된 명제(가설)에 대한 증거가 데이터에 뚜렷이 나타나는가를 판단하는 것 -주어진 모수와 sample $\rightarrow$ sample에서 모수추정 $\rightarrow$ 차이가 유의미하게 나는가? -가설검정 = 유의성검정: 귀무가설에 대한 반증의 강도를 제공하는 과정 -표본분포의 종류에 따라 검정방법 달라짐
검정통계량	-귀무가설에 대한 반증의 강도를 산출해주는 수식: 'Z'
검정통계값	-검정통계량에 의해 계산된 값: 'Z-값' -기대값보다 굉장히 크거나 작을수록 반증력 강함
유의수준	-귀무가설의 기각 여부를 결정하는 기준, α
임계값	-귀무가설의 기각여부를 판정하는 기준이 되는 기준값
제1종 오류	-옳은 귀무가설을 기각
제2종 오류	-틀린 귀무가설을 채택
유의확률	-검정통계값보다 더 극단적인 값이 나올 확률 -기존 방식 보완: (표준화된) 임계값과 검정통계값의 비교 $\rightarrow$ 유의확률 < 유의수준이면 귀무가설 기각 -유의확률의 다양성(강도) 보여줄 수 있음
적합도 검정	-한 개의 범주 변수(명목척도)에 대한 빈도 검정 -관찰빈도와 기대빈도의 차이에 대한 검정 -카이-스퀘어 검정 $\rightarrow$ 검정통계량 $\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} (df = k - 1)$

1.5. 분산분석과 상관분석

분산분석	-두 가지 관점 (일원분산분석) 3집단 간의 평균 차이 있는가? - 집단을 구분하는 기준이 유의미한가? -집단 간 유의미한 평균차가 있는지를 변동의 비율을 통해 결정 -집단 간 변동이 집단 내 변동보다 충분히 큼 $\rightarrow$ 집단들 사이에 유의미한 차이 있음 - 집단 간 변동: 집단의 평균 - 전체 평균 ($\rightarrow$ 회귀식이 설명한 변동) - 집단 내 변동: 개별 값 - 집단의 평균 ($\rightarrow$ 회귀식의 잔차) -F-검정 실행 (항상 단측검정): $F = MSB/MSW = \text{집단간/집단내}$ -개별 집단쌍에 대해 실행하지 않는 이유: FWER 문제 - 여러 개의 가설 동시에 검정할 때 적어도 하나의 가설에서 제1종 오류가 발생할 확률 (FWER) $\rightarrow$ 동시 검정의 개수 많아질수록 증가
상관분석	-두 변수가 얼마나 함께 변화하는가? $\rightarrow$ 'covary' (상관관계는 공변동의 측정)
공변동	-분산 개념의 이변량화
피어슨 상관계수	-공분산을 두 표준편차의 곱으로 나눔 -다른 관점: 두 표준점수 곱의 평균 $r = \frac{S_{xy}}{S_x S_y} = \frac{1}{n-1} \sum z_{x_i} z_{y_i} \rightarrow \text{t-검정}$ -해석: 방향 + 크기 - 양의 상관 vs. 음의 상관: 한 변수의 값이 상대적으로 클 때 다른 변수의 값 상대적으로 큼/작음 - 높은 상관 vs. 낮은 상관: 선형성의 정도 (특정한 상관성이 얼마나 일관성 있게 나타나는가?)

1.6. 회귀분석

*k = (독립변수의 개수 + 1)로 정의된다. (parameter의 개수)

회귀분석	-변수들 간의 함수적(인과적) 관련성을 정식화하고 그것에 대한 유의성 검정을 제공 • 종속변수의 변동의 몇 %를 독립변수가 설명하는가? $\square$ 결정계수, F-검정 • 각 독립변수는 통계적으로 유의미한 원인인가? $\square$ 회귀계수, t-검정
단순회귀분석	-총변동의 분해: $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + e_i = (\hat{Y}_i - \bar{Y}) + (Y_i - \hat{Y}_i) = \text{설명변동} + \text{잔차변동}$ -모집단: $E[Y] = \beta_0 + \beta_1 X \quad / \quad Y = E[Y] + \epsilon$ -표본: $\hat{Y} = b_0 + b_1 X \quad / \quad Y = \hat{Y} + \epsilon$
회귀계수	-OLS 추정: 총제곱합(TSS) = 설명제곱합(ESS) + 잔차제곱합(RSS) $\square$ RSS의 최소화 • alternative: 총제곱합(TSS) = 회귀제곱합(RSS) + 오차제곱합(ESS) -절편: X가 0일 때 Y의 기댓값(의 추정치 = 평균) -기울기: X가 1단위 증가함에 따라 증감하는 Y의 단위수 -검정: t-검정 • 추정값의 표준오차가 작을수록 검정통계량 커짐 • 전체 모델의 표준오차가 각 변수의 유의성에 영향
잔차	-양의 잔차: 과소추정 (실측 > 추정) -음의 잔차: 과대추정 (실측 < 추정) -공간통계학에서 위배되는 가정들: 잔차의 공간적 자기상관성, 이분산성(y가 커질수록 잔차 분산 커짐)
다중회귀분석	-필요성: 다중인과성 $\square$ 순수한 인과성 추정 -독립변수 각각의 순수한 종속변수에 대한 인과력을 측정함으로써 독립변수군이 종속변수에 대해 갖는 총체적인 인과성의 모델을 도출
회귀계수	-OLS 추정 -$b = (X^T X)^{-1} X^T y$ -절편: 모든 독립변수가 0일 때 종속변수의 기댓값 -기울기: 다른 모든 독립변수의 효과를 통제했을 때, 특정 독립변수 한 단위가 증가함에 따라 증감하는 종속변수의 단위수 ($r_{YX_1 X_2}$) -검정: t-검정 ($t = \frac{b}{s_b}$) $\square$ 각 변수가 독립적일수록 good! (다중공선성 문제) • $S = s_e^2 (X^T X)^{-1} \rightarrow \sqrt{\text{diag}(S)} \rightarrow s_{b_0}, s_{b_1}, s_{b_2}, \dots, s_{b_{k-1}}$ • $s_{b_j} = \frac{s_e}{\sqrt{RSS_j}} = \frac{s_e}{\sqrt{(1-R_j^2)TSS_{X_j}}} = \frac{1}{\sqrt{1-R_j^2}} \times \frac{s_e}{\sqrt{\sum (x_{ij}-\bar{x})^2}} = \sqrt{VIF_j} \times \frac{s_e}{\sqrt{\sum (x_{ij}-\bar{x})^2}}$ • R_j^2: j번째 독립변수를 종속변수로 두고 나머지 독립변수를 독립변수로 둔 회귀분석의 결정계수 • VIF(variance inflation factor, 분산팽창인자)
표준화 회귀계수	-독립변수의 상대적 영향력(설명력) -$b_0^* = 0, \quad b_j^* = b_j \frac{s_{X_j}}{s_Y}$
추정값의 표준오차	-잔차의 표준편차, 평균제곱근오차 (RMSE) -$\hat{\sigma}_\epsilon = s_e = \sqrt{\frac{RSS}{n-k}} \quad \square$ 작으면 작을수록 좋음
결정계수	-TSS에 대한 ESS의 비중 = 종속변수의 변동을 독립변수(회귀식)이 설명한 비중 -$R^2 = \frac{ESS}{TSS} = \frac{s_{\hat{Y}}^2}{s_Y^2} = r_{Y\hat{Y}}^2 = r^2$ (마지막 등호는 단순회귀의 경우에만 성립) -조정 $R^2 = R^2 - \frac{k-1}{n-k} (1-R^2) \quad \square$ k가 커지는 것에 대한 페널티
가설검정	-ANOVA(F-검정) *항상 단측검정 -$F = \frac{MSE}{MSR} = \frac{R^2/(k-1)}{(1-R^2)/(n-k)}$

→ k = 2개의 수.

	제곱합 SS	자유도 df	평균제곱합 MS	검정통계량
집단간	BSS	$k - 1$	$MSB = \frac{BSS}{k - 1}$	$F = \frac{MSB}{MSW}$
집단내	WSS	$n - k$	$MSW = \frac{WSS}{n - k}$	
전체	TSS	$n - 1$		

	제곱합 SS	자유도 df	평균제곱합 MS	검정통계량
Model (회귀분석)	ESS	$k - 1$	$MSE = \frac{ESS}{k - 1}$	$F = \frac{MSE}{MSR}$
Residual (잔차)	RSS	$n - k$	$MSR = \frac{RSS}{n - k}$	
Total (전체)	TSS	$n - 1$		

-결과 해석

- GOF = 조정 R^2
- 표준화 회귀계수(+ t, p-value): 더 중요한 독립변수 무엇인지 판별

가정의 검토

- 이분산성, 비정규성, 자기상관 → normal i.i.d.
- 비선형성
- 다중공선성
- 유력개체

normal i.i.d.

- 각 데이터 개체에서 발생하는 잔차는 특정한 확률변수의 확률분포에 의거해 발생: $\epsilon \sim N(0, \sigma^2 I)$
- 항등(정규)분포: 모든 데이터 포인트에서 확률변수는 동일한 정규분포를 보임 → $\epsilon \sim N(0, \sigma^2)$
- 독립분포: 한 데이터 포인트에서의 확률변수는 다른 데이터 포인트에서의 확률변수와 아무런 관련이 없음
→ $Cov[\epsilon_i, \epsilon_j] = 0$